

Задание основано на вычислении метрик рёбер и применении их для предсказания появления рёбер в темпоральных (временных) графах. Идея задания взята из статьи Bruin, Gerrit Jan de; Veenman, Cor J.; van den Herik, H. Jaap; Takes, Frank W. (2021): Supervised temporal link prediction in large-scale real-world networks. In Soc. Netw. Anal. Min. 11 (1). DOI: 10.1007/s13278-021-00787-3.

Данные

Для работы предлагаются датасеты, размещенные на <http://konect.cc/networks/> и представляющие собой реальные сети различной природы (социальные, информационные, технологические). Каждый датасет – это темпоральный (временной) граф, где для каждого ребра указана временная отметка в промежутке от t' до t'' – время появления ребра в графе. Все графы считать неориентированными.

$H_{[t', t'']}(E, V_H)$ – временной граф с множеством рёбер $E_H = \{(u, v, t), u, v \in V, t' \leq t \leq t''\}$.

Статический граф $G = (V, E_G)$ – граф, полученный из графа $H_{[t', t'']}$, путем сохранения всех рёбер, появившихся в графе от t' до t'' (без учета кратности рёбер).

1. Свойства сетей (для статических графов)

Для каждой из сетей вычислить следующие характеристики

1. Число вершин, число рёбер, плотность (отношение числа рёбер к максимально возможному числу рёбер), число компонент слабой связности, долю вершин в максимальной по мощности компоненте слабой связности.
2. Для наибольшей компоненты слабой связности вычислить/оценить значения радиуса, диаметра сети, 90 перцентиля расстояния (геодезического) между вершинами графа. Оценку провести на основании
 - а. вычисления расстояний между 500 (1000) случайно выбранными вершинами из наибольшей компоненты слабой связности;
 - б. вычисления расстояний по подграфу "снежный ком" (snowball sample), построенного по следующему принципу: выбирается небольшое начальное множество вершин (2 или 3), затем в граф добавляются все их соседи, затем соседи соседей и т.д., пока число вершин в подграфе не станет равным (примерно) заданному значению (например, 500 или 1000).
3. Для наибольшей компоненты слабой связности вычислить средний кластерный коэффициент сети $\bar{cl} = \frac{1}{|V|} \sum_{u \in G} cl_u$, где

$$Cl_u = \begin{cases} \frac{2L_u}{|\Gamma(u)| \cdot |\Gamma(u)-1|}, & |\Gamma(u)| \geq 2 \\ 0, & \text{иначе.} \end{cases},$$

где $\Gamma(u)$ – множество соседей вершины, $|\Gamma(u)| = k_u$ – степень вершины, L_u --- число ребер между соседями.

4. Коэффициент ассортативности по степени вершин $-1 \leq r \leq 1$ (коэффициент корреляции Пирсона)

$$r = \frac{\sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) k_i k_j}{\sum_{i,j} \left(k_i \delta_{ij} - \frac{k_i k_j}{2m} \right) k_i k_j} = \frac{R_e R_1 - R_2^2}{R_3 R_1 - R_2^2},$$

где $R_1 = \sum_i k_i = 2m$, $R_2 = \sum_i k_i^2$, $R_3 = \sum_i k_i^3$, $R_e = \sum_{i,j} A_{ij} k_i k_j$.

Случаю, когда в сети вершины малой степени чаще соединяются с вершинами большой степени, соответствуют отрицательные значения коэффициента $r < 0$.

2. Предсказания появления ребер в графе

Основная задача проекта – предсказать, появится ли ребро между парой вершин (u, v) к моменту времени t'' , если на момент времени t^* ребро между этими вершинами отсутствовало, т. е. фактически, решается задача бинарной классификации.

Для предсказания необходимо сначала построить признаковое описание для каждого потенциального ребра (вектор/набор признаков) $X_{(u,v)}$, а также ответ $y_{(u,v)}$, который принимает значение $y_{(u,v)} = 1$, если ребро появляется в графе, и $y_{(u,v)} = 0$, иначе.

А. Построение векторов признаков для предсказания появления ребер в графе.

В работе [1] предлагается несколько вариантов построения признакового описания, а затем сравнивается качество полученных предсказаний. Нужно построить два различных набора признаков: статический (I) и один из II-A(см. Статью).

Б. Бинарная классификация.

Для обучения модели применяется алгоритм логистической регрессии. Для оценки качества построенной модели используется метрика AUC(Area Under the Receiver Operating Curve) – площадь под ROCAUC–кривой. ROCAUC–кривая строится на основании соотношения доли верно классифицированных объектов, обладающих некоторым свойством(TPR - truepositiverate) и доли объектов, не обладающих свойством, но ошибочно классифицированных как обладающие этим свойством (FPR - falsepositiverate), при различных уровнях порога принятия решения.

TPR–доля рёбер, которые появились в графе $y_{(u,v)}=1$ и которые классификатор отметил, как появившиеся в графе.

FPR–доля рёбер, которые не появились в графе, но которые были отмечены, как появившиеся.